# Машинное обучение и интеллектуальный анализ данных

## Семинар 3

Г.А. Ососков\*, О.И. Стрельцова\*, Д.И. Пряхина\*, Д.В. Подгайный\*, А.В. Стадник\*, Ю.А. Бутенко\* Государственный университет «Дубна» \*Лаборатория информационных технологий, ОИЯИ Дубна, Россия

Государственный университет «Дубна»

#### Задачи машинного обучения. Задачи классификации








Реализация средствами Python Реализация средствами Python + NumPy Реализация средствами Python + NumPy + Scikit-Learn

matplotlib — для визуализации данных, результатов и т.д.

seaborn: statistical data visualization

Data generation for classification tasks:



from sklearn.datasets.samples\_generator import make\_blobs

Библиотека scikit-learn. Machine Learning in Python: <a href="https://scikit-learn.org/dev/">https://scikit-learn.org/dev/</a>



#### 1. Генерация данных (модельных)

#### from sklearn.datasets import make\_blobs

```
X, y = make blobs(n samples=100, centers=2, n features=2,
                     random state=0, cluster std=0.60)
  print(X.shape)
  plt.scatter(X[:, 0], X[:, 1], c=y, edgecolor="grey", s=50, cmap='coolwarm');
  print(y)
                                         5
Смоделированные данные:
                                         4
2 центра;
2 признака;
                                         3
Параметр
cluster std= 0.6
                                         2
                                         1
Изменяем параметр
(Стандартное отклонение кластеров):
cluster_std (0.9;1.0,1.6,2.6)
                                            -0.5
                                                 0.0
                                                      0.5
                                                           1.0
                                                                1.5
                                                                     2.0
                                                                         2.5
                                                                              3.0
                                                                                   3.5
```

Библиотека scikit-learn. Machine Learning in Python:

Generate isotropic Gaussian blobs for clustering.

https://scikit-learn.org/stable/modules/generated/sklearn.datasets.make blobs.html




#### Генерация данных (модельных)

Изменяем количество центров: centers = 3, cluster std= 0.6

Цвет признака передается через  $\mathbf{c} = \mathbf{v}$ 



Обратите внимание какой массив сгенерирован: print(X.shape)



Библиотека scikit-learn. Machine Learning in Python:

Generate isotropic Gaussian blobs for clustering.

https://scikit-learn.org/stable/modules/generated/sklearn.datasets.make blobs.html

### Метод k ближайших соседей: K-means



#### **Mathematical formulation**

The KMeans algorithm clusters data by trying to separate samples in n groups of equal variance, minimizing a criterion known as the *inertia* or within-cluster sum-of-squares (see below). This algorithm requires the number of clusters to be specified. It scales well to large number of samples and has been used across a large range of application areas in many different fields.

The k-means algorithm divides a set of N samples X into K disjoint clusters C, each described by the mean  $\mu_j$  of the samples in the cluster. The means are commonly called the cluster "centroids"; note that they are not, in general, points from X, although they live in the same space.

The K-means algorithm aims to choose centroids that minimise the inertia, or within-cluster sum-of-squares criterion:

$$\sum_{i=0}^{n} \min_{\mu_j \in C} (||x_i - \mu_j||^2)$$

### Метод k ближайших соседей: KNeighborsClassifier



#### **Example**

```
>>> X = [[0], [1], [2], [3]]
>>> y = [0, 0, 1, 1]
>>> from sklearn.neighbors import KNeighborsClassifier
>>> neigh = KNeighborsClassifier(n_neighbors=3)
>>> neigh.fit(X, y)
KNeighborsClassifier(...)
>>> print(neigh.predict([[1.1]]))
[0]
>>> print(neigh.predict_proba([[0.9]]))
[[0.66666667 0.33333333]]
```